

Terremotos en el sur de Asia

¿en que zonas hay y por qué?

Proyecto de Fundamentos en Ciencia de Datos

Santiago Correa Marulanda^{1,2*}

¹Universidad de Antioquia

²Facultad de Ingeniería

³Departamento de Ingeniería de Sistemas

Resumen

En este artículo se estudiaron los diferentes factores y características de los sismos ocurridos en el sur de Asia, con el objetivo de identificar en que zonas se generan más terremotos y que variables pueden explicar este fenómeno con mayor precisión. Se utilizó un conjunto de datos público de la plataforma de Kaggle que contiene información de parámetros físicos, meteorológicos y espaciales, de las cuales se seleccionaron un subconjunto para realizar proyecto académico. A través de técnicas de Análisis Exploratorio de Datos (EDA) y de visualización se identifican patrones en las distribuciones de los datos, como lo es que la cantidad de sismos superficiales es mayor que los profundos, la poca variación de la vibración del suelo, la relación o redundancia que hay entre diferentes datos y los atípicos observados. Con el preprocesamiento se hizo una limpieza para mejorar el estudio y facilitar el proceso de las diferentes técnicas para llevar a cabo el análisis. Para finalizar se interpretan los resultados para determinar si con las condiciones de este estudio es posible tener mayor conocimiento sobre la ocurrencia de este fenómeno.

Introducción

Los terremotos son uno de los fenómenos naturales con mayor impacto social, económico y humano. Identificar patrones en dónde ocurren con mayor frecuencia y qué características presentan es fundamental para entender mejor la amenaza sísmica de una región y apoyar procesos de planificación y toma de decisiones. Aunque el estudio de estos fenómenos, cuenta con modelos físicos muy desarrollados, en la práctica también es útil aplicar herramientas de ciencia de datos para explorar grandes catálogos de eventos y extraer patrones estadísticos.

En este trabajo se analiza un conjunto de datos de terremotos ocurridos en el sur de Asia, tomado de la plataforma pública Kaggle. El catálogo incluye información sobre la localización de los sismos (latitud y longitud), su profundidad, la magnitud y el tipo de magnitud utilizado, así como variables temporales y de estado del registro. A partir de este conjunto se seleccionó un subconjunto reducido de variables, centrado en aquellas que permiten describir dónde se generan los terremotos y con qué características físicas típicas lo hacen.

El objetivo principal del estudio es responder, en la medida en que los datos lo permiten, a dos preguntas: Primero, en qué zonas del sur de Asia se concentra la actividad sísmica registrada en el catálogo y, qué patrones se observan en términos de profundidad, magnitud, tipo de magnitud y tiempo de los eventos.

Para ello se diseñó un flujo de trabajo que incluye un análisis exploratorio de datos (EDA), el tratamiento de valores faltantes y atípicos, la transformación de variables categóricas y temporales, y la construcción de un conjunto de datos limpio sobre el cual realizar las visualizaciones y resúmenes estadísticos.

Se debe aclarar que el desarrollo de este proyecto se basa en el análisis usando técnicas de Ciencia de Datos y que su enfoque es principalmente exploratorio. No se busca construir un modelo predictivo ni explicar de forma exhaustiva las causas físicas de los terremotos en la región, sino más bien mostrar cómo, a partir de un catálogo real y un conjunto limitado de variables, es posible aplicar técnicas básicas de ciencia de datos para obtener descripción razonable de los sismos que hay en el dataset.

Metodología

En este trabajo se utilizaron dos notebooks principales: un primer notebook dedicado al Análisis Exploratorio de Datos (EDA) inicial y selección de variables, y un segundo cuaderno enfocado en el preprocesamiento detallado, la imputación de datos faltantes y la construcción del conjunto de datos final para el análisis.

Conjunto de datos y selección de variables

El punto de partida fue un conjunto de datos público de terremotos en el sur de Asia, que contiene decenas de miles de registros con información física, espacial

*Corresponding author: santiago.correa7@udea.edu.co

Received: Noviembre 27, 2025, Published: Noviembre 27, 2025

y temporal de cada evento. Dado que el objetivo del proyecto es estudiar dónde se concentran los terremotos y con qué características típicas ocurren, se seleccionó un subconjunto de variables consideradas más relevantes:

Variables numéricas

- latitude: latitud del epicentro.
- longitude: longitud del epicentro.
- depth: profundidad del hipocentro (km).
- mag: magnitud del evento.
- rms: valor rms asociado a la señal sísmica.

Variables categóricas

- time: fecha y hora del evento.
- magTyp': tipo de magnitud utilizada (por ejemplo, Mw, Mb, Ms).
- type: tipo de evento (por ejemplo, earthquake, explosion).
- status: estado del registro (reviewed, automatic, etc.)

Esta selección se definió en el primer notebook, donde también se verificó la consistencia básica de los datos, los tipos de cada columna y la presencia de valores faltantes.

Análisis exploratorio inicial

En la fase de EDA se utilizaron estadísticas descriptivas y visualizaciones sencillas:

- Uso de resúmenes numéricos (describe) para evaluar medias, medianas, desviaciones estándar y rangos de depth, mag y rms
- Histogramas y curvas de densidad para identificar sesgos y colas largas en las distribuciones.
- Gráficos de dispersión de latitude vs longitude para visualizar la distribución espacial de los epicentros.
- Tablas de frecuencia y gráficos de barras para las variables categóricas (magType, type, status).

A partir de este análisis se observó que la mayoría de los sismos eran superficiales, que las magnitudes pequeñas y moderadas eran mucho más frecuentes que las grandes, que rms presentaba poca variación alrededor de un valor típico y que magType, aunque muy detallada, tenía muchas categorías poco frecuentes y fuertemente relacionadas entre sí, es decir, muchas de las formas en las que se toman los datos, derivan de otros. También se identificó que rms era la única variable con una proporción apreciable de datos faltantes, alrededor del 9 por ciento, mientras que el resto de variables seleccionadas no tenía datos faltantes.

Tratamiento de datos faltantes

Dado que rms presentaba datos faltantes, se exploraron distintas estrategias de imputación. Primero se consideró una imputación sencilla con la mediana de rms, como referencia básica. Luego se probó la imputación mediante modelos de regresión supervisada. Un modelo de Random Forest Regressor, utilizando como predictores latitude, longitude, depth y mag.

Un modelo de K-Nearest Neighbors Regressor (KNN) con un número reducido de vecinos y pesos por distancia.

Para cada modelo se trabajó únicamente con las filas donde rms no era NaN, dividiendo los datos en un conjunto de entrenamiento y uno de validación (80 % y 20 %). Se ajustaron los modelos y se evaluaron con métricas de error absoluto medio (MAE) y coeficiente de determinación (R^2). Los resultados mostraron que el Random Forest lograba un R^2 modesto, pero ligeramente mejor que la imputación por mediana, mientras que KNN no aportaba mejoras relevantes.

Ya que el objetivo del trabajo es exploratorio y no se requiere una imputación perfecta, se decidió utilizar la imputación basada en Random Forest para completar los valores faltantes de rms. Con esta imputación se construyó un conjunto de datos intermedio (data_imputed), del cual se obtuvo una copia de trabajo (data_cleaned) para el resto del preprocesamiento.

Detección y manejo de valores atípicos

En el primer notebook se identificaron posibles valores atípicos en mag y rms utilizando el z-score. Se fijaron umbrales numéricos para considerar como atípicos los valores muy bajos o muy altos en comparación con la mayoría de los datos, por ejemplo, magnitudes menores a 2.94 o mayores a 6.18, y valores de rms inferiores a 0.09 o superiores a 1.73. Inicialmente se discutió que estos casos podrían corresponder a eventos reales de gran magnitud o registros particulares de la señal y que no necesariamente debían eliminarse.

En el segundo notebook, y con el fin de trabajar sobre un conjunto más aplicado a eventos típicos, se implementó la eliminación que sobrepasaban los umbrales de atípicos, en mag y rms. Para la variable depth se probó primero un criterio basado en el rango intercuartílico (IQR), pero este producía demasiados atípicos debido al fuerte sesgo de la distribución y también por no cumplir muy bien con los supuestos. Por ello se aplicó un modelo de Isolation Forest, con una proporción baja de contaminación (aproximadamente el 1 %), para identificar profundidades poco frecuentes. Los registros marcados como atípicos por

este modelo también se eliminaron en la versión final de trabajo.

Es importante que notemos que estas decisiones reducen la presencia de eventos extremos muy profundos o muy energéticos, por lo que las conclusiones se centran en los terremotos más representativos del dataset.

Transformación de variables categóricas y temporales

Las variables categóricas y temporales se transformaron para simplificar el análisis y mejorar la interpretabilidad

magType se agrupó en una nueva variable magType_group, que la componen tipos de magnitud en categorías más amplias, por ejemplo, magnitud de momento Mw, ondas de cuerpo Mb, ondas superficiales Ms, magnitud local/duración MI/Md y un grupo “Otro” para casos raros. Tras crear esta variable, se eliminó la columna original magType.

type se utilizó para filtrar el conjunto de datos, manteniendo únicamente los registros clasificados como earthquake y descartando otros tipos de eventos sísmicos poco frecuentes, como explosiones o colapsos.

status se revisó para eliminar los registros con valor automatic, debido a su baja frecuencia y menor confiabilidad, manteniendo principalmente eventos revisados.

time se convirtió a formato de fecha y hora y se descompuso en tres variables numéricas: year (año), month (mes) y hour (hora). La columna original time se eliminó posteriormente para trabajar únicamente con estas representaciones más manejables.

Tras todas estas etapas, se obtuvo un conjunto de datos limpio ‘data_cleaned’ compuesto por variables numéricas latitude, longitude, depth, mag, rms, year, month, hour) y variables categóricas transformadas (magType_group, y en algunos casos una versión simplificada de status. Sobre este conjunto se realizaron las visualizaciones y análisis que se presentan en la sección de resultados.

Resultados y Análisis

En esta sección se presentan los principales resultados obtenidos a partir del conjunto de datos preprocesado (data_cleaned). El análisis se organiza en tres ejes: patrones espaciales, patrones temporales y características físicas de los sismos (profundidad, magnitud y tipo de magnitud).




Figure 1: *Anther of thale cress (Arabidopsis thaliana), fluorescence micrograph.* Source: Heiti Paves, <https://commons.wikimedia.org/wiki/File:Tolmukapea.jpg>.

¿dónde se concentran los terremotos?

El gráfico de dispersión de la latitud frente a la longitud muestra que los terremotos no se distribuyen de forma uniforme en el área de estudio, sino que se agrupan en franjas bien definidas. Estas franjas probablemente corresponden a zonas tectónicamente activas del sur de Asia, donde la interacción entre placas favorece a la actividad sísmica. Caso contrario para grandes zonas de la región donde se ven cero o casi ninguna actividad.

Para complementar este resultado, se calcularon conteos de eventos entre latitud y longitud redondeadas, por ejemplo, a grados enteros. Las tablas de frecuencia muestran que unas pocas combinaciones latitud-longitud concentran una proporción importante del total de terremotos, identificándose así “puntos calientes” de actividad sísmica dentro de la región. Estos patrones espaciales son coherentes con la existencia de fallas o zonas de subducción específicas.

¿cómo varía la actividad en el tiempo?

El conteo anual de terremotos muestra que el número de eventos registrados varía a lo largo de los años. Se observan periodos con más sismos catalogados y otros con menos, lo que puede deberse tanto a cambios reales en la actividad sísmica como a la evolución de la detección de señales (más estaciones, mejor sensibilidad y capacidad de registro en años recientes). En este sentido, el incremento del número de registros en ciertos periodos no debe interpretarse únicamente como un aumento físico de la sismicidad, sino como una combinación de factores físicos e instrumentales.



Figure 2: *Anther of thale cress (Arabidopsis thaliana), fluorescence micrograph.* Source: Heiti Paves, <https://commons.wikimedia.org/wiki/File:Tolmukapea.jpg>.




Figure 3: *Anther of thale cress (Arabidopsis thaliana), fluorescence micrograph.* Source: Heiti Paves, <https://commons.wikimedia.org/wiki/File:Tolmukapea.jpg>.

Cuando se agrupan los eventos por mes, la distribución no muestra una tendencia fuerte: algunos meses presentan algo más de actividad que otros, pero las diferencias no son extremas. Esto sugiere que, la ocurrencia de sismos no está claramente ligada a una época del año específica. Del mismo modo, la distribución de eventos por hora del día es relativamente homogénea, lo que concuerda con el hecho de que los terremotos no dependen de ciclos diarios.

Conclusiones

El análisis realizado sobre el dataset de sismos en el sur de Asia permitió identificar que la actividad sísmica no es uniforme, sino que se concentra en franjas específicas de latitud y longitud, que pueden interpretarse como zonas sísmicamente más activas dentro de la región.

En términos de características físicas, se observó que la mayoría de los terremotos son superficiales y de magnitud baja o moderada, mientras que los eventos muy profundos o de gran magnitud son poco frecuentes. Parte de estos casos extremos fue filtrada en el preprocesamiento, por lo que las conclusiones describen principalmente el comportamiento de los sismos más típicos del conjunto de datos.

En conjunto, las variables seleccionadas y transformadas permiten describir patrones generales sobre dónde se concentran los terremotos del dataset y cuáles son sus características más frecuentes (profundidad, magnitud, tipo de magnitud y distribución temporal).

Sin embargo, estos resultados se deben interpretar con cautela, ya que: El análisis se centra en un subconjunto de datos tras la imputación de rms y la eliminación de ciertos outliers y la base de datos refleja tanto la actividad sísmica real como las limitaciones e inconsistencias del sistema de registro.

Por lo tanto, más que ofrecer una explicación definitiva de las causas de los terremotos, este estudio proporciona una descripción estadística de los sismos típicos presentes en el conjunto de datos estudiado.